

Universidad de San Andrés, *Buenos Aires, Argentina*



I206 - Inferencia y Estimación

Trabajo Práctico II

Codificación de Huffman

Camiscia, Luca

lcamiscia@udesa.edu.ar

Palavecino, Axel

apalavecino@udesa.edu.ar

Pereyra, Agustín

apereyra@udesa.edu.ar

21 de octubre de 2025

Abstract

En este presente trabajo se aborda experimentalmente este principio, investigando cómo se desempeña en la práctica el algoritmo de **Codificación de Huffman**, donde se investiga cómo la capacidad predictiva de una fuente determina su potencial compresión, esto se hace mediante el análisis de textos con propiedades de ocurrencia de caracteres radicalmente diferentes (lenguaje natural, datos estructurados y secuencias genómicas), además de demostrarse empíricamente la optimalidad de este método. Los resultados cuantifican la eficiencia del algoritmo, que minimiza la longitud de codificación promedio ... (Aca van el resto de los resultados)

1. Introducción

En la era del **Big Data**, obtener capacidad de representar información de manera concisa y compacta es un desafío fundamental. La *Teoría de la Información*, la cual comenzó **Claude Shannon**,

postula que la compresibilidad de cualquier dato está intrínsecamente limitada por su contenido de incertidumbre, esta medida es cuantificable, y es conocida como *entropía*.

2. Desarrollo Experimental

2.1. Estimación del Modelo probabilístico de la Fuente

El primer paso en la implementación de la **codificación de Huffman** es estimar el modelo probabilístico de la fuente (texto). Esto se logra mediante el análisis de la frecuencia de aparición de cada símbolo en el conjunto de datos. La probabilidad p_i de cada símbolo s_i se calcula como:

$$p_i = \frac{f_i}{\sum_{j=1}^N f_j} \quad (1)$$

, donde cada caracter es una realización de la variable aleatoria fuente S . El objetivo en esta etapa es estimar una **función de masa de probabilidad (PMF)** de cada fuente de texto. El resultado de este paso es un conjunto de pares (s_i, p_i) que representan los símbolos y sus probabilidades de ocurrencia, es decir, su **probabilidad empírica** de aparición $p(x)$. En este informe no se realiza una distinción entre mayúsculas y minúsculas, ya que el objetivo principal es reducir el tamaño del texto manteniendo su compresibilidad. La ausencia de mayúsculas al inicio de las oraciones no afecta la comprensión, por lo que se considere prescindible. No obstante, posteriormente podría aplicarse un .Este diccionprograma que reemplace automáticamente por mayúsculas las letras que sigan a un punto ("."). Este diccionario constituye el modelo estadístico de la fuente, y es el insumo fundamental sobre el cual operará el algoritmo de **Huffman**.

Las características de este resultado se basan en los **Aximas de la Probabilidad**, es decir, la suma

de los p_i es igual a 1, $\sum_{i=1}^N p_i = 1$, la probabilidad de un evento puntual es mayor a cero, $\mathbb{P}(p_i) \geq 0$, y si $A \cap B = \emptyset \Rightarrow \mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$

2.2. Codificación de Huffman

2.3. Construcción del Árbol de Huffman

2.4. Medidas de Desempeño y Análisis Cuantitativo

Longitud Promedio de Codificación (L):

$$L = \sum_{i=1}^N p_i l_i \quad (2)$$

Comparación con la Codificación Uniforme

$$L_{\text{unif}} = \lceil \log_2(N) \rceil \quad (3)$$

Reducción de Memoria

$$R = \left(1 - \frac{L}{L_{\text{unif}}}\right) \times 100 \% \quad (4)$$

Compresibilidad de la Fuente (Entropía Normalizada, η)

$$\eta = \frac{H(S)}{\log_2(N)} \quad (5)$$

3. Análisis de Datos

4. Conclusión